

DOCUMENTAÇÃO

1. Inscrição no *BigQuery*;
2. Criação do Projeto **projeto-2-spotify**;
3. Logo em seguida, criação do banco de dados (**projeto_dataset**) em que seriam importados as seguintes tabelas disponibilizadas em **CSV**:
 - a. track_in_competition - competition;
 - b. track_in_spotify - spotify;
 - c. track_technical_info - technical_info;
4. Teve a primeira dificuldade , pois o nome da coluna existia um carácter não aceito;
5. Foi realizada a limpeza manual desse único erro que impedia a importação da tabela **track_in_spotify**;
6. Depois, foi iniciado os testes e armazenamento das seguintes consultas (queries):
7. **(5.1 - Processar e preparar a base de dados)**
 - a. 5.1.1 - Conectar/importar dados para outras ferramentas
 - b. 5.1.2 - Nulos - track_in_competition - [\(Link\)](#)
 - i.

```
# track_in_competition

SELECT
  COUNT (*)
FROM
  `projeto-2-spotify.projeto_dataset.track_in_competition`
WHERE in_apple_playlists IS NULL

SELECT
  COUNT (*)
FROM
  `projeto-2-spotify.projeto_dataset.track_in_competition`
WHERE in_apple_charts IS NULL

SELECT
  COUNT (*)
FROM
  `projeto-2-spotify.projeto_dataset.track_in_competition`
WHERE in_deezer_playlists IS NULL

SELECT # 50 RESULTADOS NULOS
  COUNT (*)
FROM
```

```
`projeto-2-spotify.projeto_dataset.track_in_competition`  
WHERE in_shazam_charts IS NULL
```

c. 5.1.2 - Nulos - track_in_spotify - [\(Link\)](#)

i.

```
# track_in_spotify  
  
SELECT # EM TODA A TABELA HÁ 953 REGISTROS  
  COUNT (*)  
FROM  
  `projeto-2-spotify.projeto_dataset.track_in_spotify`;  
  
SELECT  
  COUNT (*)  
FROM  
  `projeto-2-spotify.projeto_dataset.track_in_spotify`  
WHERE track_id IS NULL  
  
SELECT  
  COUNT (*)  
FROM  
  `projeto-2-spotify.projeto_dataset.track_in_spotify`  
WHERE track_name IS NULL;  
  
SELECT  
  COUNT (*)  
FROM  
  `projeto-2-spotify.projeto_dataset.track_in_spotify`  
WHERE artist_name IS NULL  
  
SELECT  
  COUNT (*)  
FROM  
  `projeto-2-spotify.projeto_dataset.track_in_spotify`  
WHERE artist_count IS NULL  
  
SELECT  
  COUNT (*)  
FROM  
  `projeto-2-spotify.projeto_dataset.track_in_spotify`
```

```

WHERE released_year IS NULL

SELECT
    COUNT (*)
FROM
    `projeto-2-spotify.projeto_dataset.track_in_spotify`
WHERE released_month IS NULL

SELECT
    COUNT (*)
FROM
    `projeto-2-spotify.projeto_dataset.track_in_spotify`
WHERE released_day IS NULL

SELECT
    COUNT (*)
FROM
    `projeto-2-spotify.projeto_dataset.track_in_spotify`
WHERE in_spotify_playlists IS NULL

SELECT
    COUNT (*)
FROM
    `projeto-2-spotify.projeto_dataset.track_in_spotify`
WHERE in_spotify_charts IS NULL

SELECT
    COUNT (*)
FROM
    `projeto-2-spotify.projeto_dataset.track_in_spotify`
WHERE streams IS NULL

```

d. 5.1.2 - Nulos - track_technical_info - ([Link](#))

i.

```

# track_technical_info

SELECT
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE track_id IS NULL

```

```
SELECT
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE bpm IS NULL
```

SELECT # RESULTADO: 95

```
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE key IS NULL
```

```
SELECT
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE mode IS NULL
```

SELECT #não tava aceitando o nome com %. Coloquei o nome da
tabela entre aspas.

```
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE "danceability_" IS NULL;
```

```
SELECT
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE "valence_" IS NULL
```

```
SELECT
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE "energy_" IS NULL
```

```
SELECT
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE "acousticness_" IS NULL
```

```
SELECT
    COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE "instrumentalness_" IS NULL
```

```
SELECT
```

```

COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE "liveness_" IS NULL

SELECT
COUNT(*)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
WHERE "speechiness_" IS NULL

```

e. 5.1.3 - Duplicados - [\(Link\)](#)

i.

```

SELECT # track_in_competition #SEM DADOS DUPLICADOS
track_id,
COUNT(*) AS quantidade
FROM
`projeto-2-spotify.projeto_dataset.track_in_competition`
GROUP BY
track_id
HAVING COUNT(*) > 1;

SELECT # track_in_spotify - valores DUPLICADOS!!!
track_name,
artist_name,
COUNT(*) AS quantidade
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`
GROUP BY track_name, artist_name
HAVING
COUNT(*) > 1;

SELECT # track_in_competition #SEM DADOS DUPLICADOS
track_id,
COUNT(*) AS quantidade
FROM
`projeto-2-spotify.projeto_dataset.track_technical_info`
GROUP BY
track_id
HAVING COUNT(*) > 1;

```

f. 5.1.4 - Fora do escopo - [\(Link\)](#)

i.

```

SELECT # TABELA: track_in_spotify
* EXCEPT(artist_count)
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`

SELECT # TABELA: track_technical_info
* EXCEPT(Key,mode)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`

# track_in_competition - não apliquei nada, vai ficar como
está.

```

g. 5.1.5 - Discrepantes - LIKE e REGEXP - [\(Link\)](#)

i.

```

# TABELA: track_in_spotify
SELECT
track_name,
REGEXP_REPLACE(track_name, r'[^a-zA-Z0-9]', '') AS
track_name_limpo
FROM
`projeto-2-spotify.projeto_dataset.track_in_spotify`;

SELECT
artist_name,
REGEXP_REPLACE(artist_name, r'[^a-zA-Z0-9]', '') AS
artist_name_limpo
FROM
`projeto-2-spotify.projeto_dataset.track_in_spotify`;

# # TABELA: track_technical_info
SELECT
key,
REGEXP_REPLACE(key, r'[^a-zA-Z0-9]', '') AS key_limpo
FROM
`projeto-2-spotify.projeto_dataset.track_technical_info`

```

h. 5.1.6 - Discrepantes - NÚMERICOS - [\(Link\)](#)

i.

```

# TABELA: track_in_competition

```

```

SELECT
MAX(in_apple_playlists) AS MAXIMO,
MIN(in_apple_playlists) AS MINIMO,
AVG(in_apple_playlists) AS MEDIA,
FROM `projeto-2-spotify.projeto_dataset.track_in_competition`

SELECT
MAX(in_deezer_playlists) AS MAXIMO,
MIN(in_deezer_playlists) AS MINIMO,
AVG(in_deezer_playlists) AS MEDIA,
FROM `projeto-2-spotify.projeto_dataset.track_in_competition`

#TABELA: track_in_spotify >>> EXEMPLO/MIRELA
SELECT
MAX(streams) AS MAXIMO,
MIN(streams) AS MINIMO,
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`

SELECT
MAX(released_year) AS MAXIMO,
MIN(released_year) AS MINIMO,
AVG(released_year) AS MEDIA,
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`

#TABELA: track_technical_info >>> APLICAR FUNÇÃO Cast
SELECT
MAX(?) AS MAXIMO,
MIN(?) AS MINIMO,
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`

```

i. **5.1.7** - ALTERAR TIPO - CAST - ([Link](#))

i.

```

SELECT
SAFE_CAST(streams AS int64) as streams_limpo,
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`

```

j. **5.1.8** - NOVAS VARIÁVEIS - ([Link](#))

i.

```

SELECT
track_id,
DATE(CONCAT(CAST(released_year AS STRING), "-",
CAST(released_month AS STRING), "-", CAST(released_day AS
STRING))) AS DATA
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`

```

k. 5.1.9 - Unir tabelas - [\(Link\)](#)

i.

```

5.19 - Unir tabelas
#TESTE - DEU CERTO - tabelas - NÃO LIMPAS
SELECT
*
FROM
`projeto-2-spotify.projeto_dataset.track_in_competition` AS tc
LEFT JOIN
`projeto-2-spotify.projeto_dataset.track_in_spotify` AS sp
ON
tc.track_id = sp.track_id
LEFT JOIN
`projeto-2-spotify.projeto_dataset.track_technical_info` AS ti
ON
tc.track_id = ti.track_id;

#TESTE - DEU CERTO - tabelas - LIMPAS
SELECT
*
FROM
`projeto-2-spotify.projeto_dataset.competition` AS tc
LEFT JOIN
`projeto-2-spotify.projeto_dataset.spotify_2` AS sp
ON
tc.track_id = sp.track_id
LEFT JOIN
`projeto-2-spotify.projeto_dataset.technical` AS ti
ON
tc.track_id = ti.track_id;

```

ii.

5.19 - Tabelas 2

SPOTIFY - EXEMPLO

```
CREATE OR REPLACE TABLE
`projeto-2-spotify.projeto_dataset.spotify` AS (
SELECT
*
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`
)
#####
#####
```

SPOTIFY 2 - LIMPA - FORA DO ESCOPO

```
CREATE OR REPLACE TABLE
`projeto-2-spotify.projeto_dataset.spotify_2` AS (
SELECT
* EXCEPT(track_name, artist_name, streams),
FROM `projeto-2-spotify.projeto_dataset.spotify`
)
```

SPOTIFY

```
CREATE OR REPLACE TABLE
`projeto-2-spotify.projeto_dataset.spotify` AS (
SELECT
track_id,
track_name,
REGEXP_REPLACE(track_name, r'[^a-zA-Z0-9 ]', '') AS
track_name_limpo,
artist_name,
REGEXP_REPLACE(artist_name, r'[^a-zA-Z0-9 ]', '') AS
artist_name_limpo,
artist_count,
released_year,
released_month,
released_day,
in_spotify_playlists,
in_spotify_charts,
streams,
SAFE_CAST(streams AS int64) as streams_limpo,
FROM `projeto-2-spotify.projeto_dataset.track_in_spotify`
)
```

```

# COMPETITION
CREATE OR REPLACE TABLE
`projeto-2-spotify.projeto_dataset.competition` AS (
SELECT
*
FROM `projeto-2-spotify.projeto_dataset.track_in_competition`
)

# TECHNICAL
CREATE OR REPLACE TABLE
`projeto-2-spotify.projeto_dataset.technical` AS (
SELECT
* EXCEPT(Key,mode)
FROM `projeto-2-spotify.projeto_dataset.track_technical_info`
)

```

iii. Criando **Tabela secundária**:

1. Primeiro, criar uma 2ª tabela igual a original, que pode ser criada já limpa - [LINK](#);
2. Mirela fez o vídeo para a gente entender a diferença entre tabela estática e view;

iv. Criando **Views**:

1. View é para ser mais prática e evitar criar muitas tabelas;
2. Criei uma **view** com a modificação de dados **discrepantes**, ou seja, modificar os campos que vem com caracteres estranhos([Link](#));
 - a.

```

#TRATEI DISCREPANTES
SELECT
track_id,
track_name,
REGEXP_REPLACE(track_name, r'[^a-zA-Z0-9]', '')
AS track_name_limpo,
artist_name,
REGEXP_REPLACE(artist_name, r'[^a-zA-Z0-9]', '')
AS artist_name_limpo,
released_year,
released_month,

```

```

released_day,
in_spotify_playlists,
in_spotify_charts,
streams,
SAFE_CAST(streams AS int64) as streams_limpo,
FROM
`projeto-2-spotify.projeto_dataset.track_in_spotify`

```

3. Nessa mesma view, fiz também a limpeza de dados numéricos [\(Link\)](#):

a.

```

#TRATEI DISCREPANTES
SELECT
track_id,
track_name,
REGEXP_REPLACE(track_name, r'[^a-zA-Z0-9]', '')
AS track_name_limpo,
artist_name,
REGEXP_REPLACE(artist_name, r'[^a-zA-Z0-9]', '')
AS artist_name_limpo,
released_year,
released_month,
released_day,
in_spotify_playlists,
in_spotify_charts,
streams,
SAFE_CAST(streams AS int64) as streams_limpo,
FROM
`projeto-2-spotify.projeto_dataset.track_in_spotify`

```

4. Então, depois de modificados os dados discrepantes, gerei uma 2ª view agora com a exclusão de colunas com os antigos dados estranhos e que agora são **fora do escopo** [\(Link\)](#):

a.

```

SELECT # TABELA: track_in_spotify
* EXCEPT(track_name, artist_name, streams)

```

```
FROM
`projeto-2-spotify.projeto_dataset.view_discrepante`
```

b.

5. Agora, tratar os dados **duplicados**:

- a. Identifiquei com uma query, quais dados duplicados.
- b. Mas para visualizar e analisar melhor, peguei a tabela original (track_in_spotify) e abri uma visualização no google sheets, através mesmo do BigQuery;
- c.  - **Resolvi aplicar essa etapa somente depois de juntar as tabelas com JOIN;**
- d.  - **Não consegui aplicar JOIN nas vistas, porque não consegui fazer uma vista da tabela "track_in_competition";**

6. Aplicando o **JOIN** nas tabelas:

- a. Juntei todas as tabelas, com e sem tratamento: fiz uma primeira junção com tabelas SEM tratamento, e depois a junção de tabela COM tratamento;
- b. Só não consegui realizar JOIN com as Views. Deu um erro (*Inserir*);
- c.

```
SELECT
*
FROM

`projeto-2-spotify.projeto_dataset.competition`
AS tc
LEFT JOIN
`projeto-2-spotify.projeto_dataset.spotify_2`
AS sp
ON
tc.track_id = sp.track_id
LEFT JOIN
`projeto-2-spotify.projeto_dataset.technical`
AS ti
ON
tc.track_id = ti.track_id;
```

d.

I. 5.1.10 - Tabelas Auxiliares:

a. (Inserir) - [\(Link\)](#)

b.

```
WITH teste AS (  
    SELECT  
        artist_name,  
        COUNT(*) AS total_musicas_solo,  
    FROM  
        `projeto-2-spotify.projeto_dataset.track_in_spot  
ify`  
    WHERE artist_count = 1  
    GROUP BY artist_name  
)  
  
SELECT  
    *  
    FROM  
        `projeto-2-spotify.projeto_dataset.track_in_spot  
ify` s  
  
    LEFT JOIN teste  
    ON s.artist_name = teste.artist_name;
```

8. (5.2 - Análise Exploratória:)

a. 5.2.1 - Agrupar dados de acordo com variáveis categóricas:

- i. para chegar aqui, já instalei o Power BI;
- ii. e agrupei dados, como sugerido;

b. 5.2.2 - Variável categórica:

- i. Não ficou muito bom, porque a lista é extensa;
- ii. Mas resolvi apenas mostrar “As 15 mais tocadas”;

c. 5.2.3 - Medidas de tendência central (média e mediana)

i. ok - simples

d. 5.2.4 - Distribuição(Histograma) - ⚠ - **Atenção - Falha!**


- i. Não consegui fazer pelo Power BI, porque houve falha na conexão com Python;

- ii. Não sei se com a versão de Python que já tinha na máquina ou com a versão de Power Bi que instalei;
 - iii. Acabei fazendo no Google Sheets ([Link](#)). Consegui, mas ficou muito simples. Se o objetivo é apenas saber o que é um Histograma, ok, meta alcançada;
- e. **5.2.5** - Medidas de dispersão - (Desvio Padrão) - **Power BI**
- i. **Dados calculados** dos Streams:
 - 1. Soma de streams_limpo - 489.458.828.542
Média de streams_limpo - 514.137.424,94
Mediana de streams_limpo - 290.530.915
Desvio padrão de streams_limpo - 566.559.151,83
Variação de streams_limpo - 320.989.272.521.701.900,00;
 - ii. **Conclusões pelo ChatGPT:**
 - 1. **Soma: 489.458.828.542** - Isso é o total de streams somando todas as observações. Por si só, não diz muito, a não ser que você saiba quantas entradas (linhas) existem;
 - 2. **Média: 514.137.424,94** - Cada item tem, em média, cerca de 514 milhões de streams. Como a média é puxada por valores extremos (outliers), ela pode não refletir bem o “centro” da distribuição se os dados forem muito desiguais;
 - 3. **Mediana: 290.530.915** - A mediana é o valor central quando os dados estão ordenados. Metade dos dados tem menos de ~290 milhões de streams. Como a mediana está bem abaixo da média, isso indica assimetria positiva (distribuição enviesada à direita): há alguns valores muito altos que puxam a média para cima;
 - 4. **Desvio padrão: 566.559.151,83** - Isso mede a dispersão dos dados em relação à média. Um desvio padrão de 566 milhões mostra que os valores estão bem espalhados ao redor da média. Isso também reforça a ideia de que há muita variação nos dados — provavelmente alguns streams muito acima da média;
 - 5. **Variação: 320.989.272.521.701.900** - A variância é o desvio padrão ao quadrado, ou seja, uma medida ainda mais sensível a valores extremos. O número gigantesco confirma uma alta dispersão nos dados;

6. **Conclusão rápida** - A distribuição dos dados é assimétrica à direita (tem muitos valores altos). Há valores extremos (provavelmente artistas ou músicas com muitos bilhões de streams). A mediana é mais confiável que a média para descrever o “centro típico” nesse caso. A dispersão é muito alta — os dados são bastante desiguais;

iii. **Histograma gerado pelo Chat:**

1.



2. O que o histograma está mostrando?(Chat GPT):

- a. O histograma agrupa os valores da sua coluna de "streams" em faixas (bins) e mostra quantas vezes os valores caem em cada faixa;

3. O que observamos nesse histograma:


- a. **Distribuição concentrada:** A maior parte dos dados está concentrada entre 50 e 150 mil streams, com picos entre 100 mil e 130 mil. Isso sugere que a maioria dos conteúdos/artistas que você analisou costumam ter desempenho mediano nesse intervalo;
- b. **Assimetria:** o gráfico tem uma leve cauda para a direita (valores altos de streams), indicando que há alguns casos raros com muitos streams (acima de 200 mil ou mais). Isso é típico de dados com long tail, muito comum em plataformas de streaming: poucos têm

muitos acessos, e muitos têm acessos medianos ou baixos;

- c. **Poucos extremos:** Quase não há valores abaixo de 20 mil ou acima de 300 mil. Então seu conjunto de dados é relativamente homogêneo, sem muitos "outliers" extremos;
- d. **Conclusão:** seu histograma indica que: A maior parte dos conteúdos analisados têm desempenho mediano, entre 50 mil e 150 mil streams. Há poucos casos de grande sucesso, mas eles existem. A distribuição é levemente assimétrica, típica de dados em que popularidade não é igualmente distribuída (normal para música, vídeos etc);

iv. **Histograma feito por mim no Sheets** (semelhante ao gerado pela IA):

Histograma de streams



1. **Conclusões** (auxílio - ChatGPT:

- a. 1. Pico claro na faixa entre 100k e 130k streams: essa é a **modalidade dominante** dos dados — ou seja, a maioria dos conteúdos/artistas está nessa faixa de audiência. Isso confirma que seu público ou sua amostragem tem **alcance mediano**, sem muitos extremos;
- b. Queda acentuada depois de 130k - os conteúdos que ultrapassam essa faixa se tornam progressivamente mais raros. Indica que poucos conteúdos alcançam status de viralidade ou sucesso massivo;

- c. Distribuição assimétrica (viés à direita) - apesar do pico central, há uma **cauda longa para a direita**. Isso sugere que existem alguns casos com muito mais streams, mas eles são exceções, não a regra;
- d. Pouca frequência abaixo de 50k - Seu histograma praticamente não mostra muitos conteúdos com menos de 50k streams. Isso pode indicar que a base analisada já parte de um **nível mínimo de popularidade**, ou que conteúdos com pouquíssimo alcance foram filtrados.;
- e. Conclusão Final: esse histograma mostra um cenário típico de distribuição de popularidade em plataformas digitais: maioria com alcance médio, poucos com alto desempenho. Um pequeno grupo pode alcançar muitos streams, mas a maioria se concentra em um intervalo mais modesto;

Resumo Estatístico Visual:

Faixa (Streams)	Frequência Visual
< 50k	Quase nula
50k – 100k	Moderada
100k – 130k	Alta (Pico)
130k – 200k	Decrescente
> 200k	Baixa

f.

- f. **5.2.6** - Comportamento dos dados ao longo do tempo:
 - i. Feito no Power BI, considerando a evolução dos streams no decorrer do tempo;
- g. **5.2.7** - Quartis, decis ou percentis - ([Link](#))
 - i. Foi criada uma View a partir da consulta salva para esta nova variável;
 - ii. Como iniciei fazendo tabelas estáticas, não ficou muito prático atualizá-las, pois criei atualizações por etapas, e o comando “CREATE OR REPLACE TABLE”, não realiza atualizações complementares, mas sim substitui a tabela, o que acabou por gerar

confusão, uma vez que os implementos teriam que se feitos de forma reversa, ou seja, nas tabelas anteriores até chegar na atual;

- iii. Criei uma View com os quartis, sua categorização e importei no Power BI;
- iv. A partir dali, pude editar a tabela no próprio BI, deixando apenas as colunas necessárias (quartile_streams e categoria_quartil);
- v.

```
WITH Quartiles AS (  
  SELECT  
    streams_limpo,  
    NTILE(4) OVER (ORDER BY streams_limpo) AS quartile_streams  
  FROM `projeto-2-spotify.projeto_dataset.spotify_2`  
)  
  
SELECT  
  a.*,  
  Quartiles, quartile_streams,  
  CASE  
    WHEN quartile_streams = 4 THEN 'Alto'  
    WHEN quartile_streams = 3 THEN 'Médio-alto'  
    WHEN quartile_streams = 2 THEN 'Médio-baixo'  
    WHEN quartile_streams = 1 THEN 'Baixo'  
    ELSE 'Sem categoria'  
  END AS categoria_quartil  
FROM `projeto-2-spotify.projeto_dataset.spotify_2` a  
  
LEFT JOIN Quartiles  
  
ON a.streams_limpo=Quartiles.streams_limpo
```

- h. **5.2.8** - correlação no BigQuery via comando CORR.:[\(Link\)](#)
 - i. Foi aplicada a fórmula CORR e usada os campos “streams_limpo,in_spotify_playlists”;
 - ii. Foi encontrado o seguinte valor: 0.78982215995506;
 - iii. Segundo ChatGPT, temos a seguinte interpretação:
 - 1. Esse valor de correlação 0.78982215995506 entre as variáveis streams_limpo (número de vezes que a música foi

- ouvida) e in_spotify_playlists (número de playlists em que a música aparece) indica uma: **Correlação positiva forte**;
2. Vamos interpretar com mais clareza: o que isso quer dizer? O valor está próximo de +1, o que indica que **quanto mais playlists a música está presente, maior tende a ser o número de streams**. A correlação é positiva, ou seja, as duas variáveis crescem juntas. E como está em torno de 0,79, trata-se de uma correlação forte, mas não perfeita (que seria 1.0);
 3. **Interpretação prática**: músicas que aparecem em mais playlists tendem a ter mais execuções no Spotify. Isso não quer dizer que estar em playlists causa mais streams (a correlação não mede causalidade), mas sim que há uma relação consistente entre essas duas variáveis;
 - 4.

```
SELECT
CORR (streams_limpo,in_spotify_playlists) AS
correlation_value
FROM `projeto-2-spotify.projeto_dataset.spotify_2`
```

9. (5.3 - Aplicar técnica de análise):

- a. **5.3.1** - Aplicar segmentação:
 - i. Interessante perceber, quando se coloca duas tabelas matrizes na mesma aba no Power BI, elas se relacionam e assim alcança um novo modo de comparação;
 - ii. Ao clicar em uma linha de uma das tabelas, acaba por filtrar a outra tabela. Por exemplo:

acousticness_%	Soma de streams_limpo	Média de c
0	305771063	
1	4371497110	
2	101780047	
3	463482382	
4	2013199682	
6	635577852	
7	325592432	
8	148461629	
9	301869854	
12	81419389	
Total	21486960547	

danceability_%	Soma de streams_limpo	Média
70	21486960547	
61	18448789560	
77	16583118933	
59	15730392981	
74	15364896013	
73	15183492858	
56	14578691515	
75	13738358686	
76	13502327502	
80	12736467667	
Total	494457439826	

iii.

- iv. Ao clicar na linha correspondente a 70 na tabela “danceability”, automaticamente a tabela “acousticness” mostra todas faixas relacionadas a linha 70 da outra tabela;
- v. Outra observação é que as linhas que possuem mais faixas, são as que receberam a classificação “**alta**” nos quartis;

acousticness_%	Soma de streams_limpo	Média de q
62	53933526	
Total	53933526	

danceability_%	Soma de streams_limpo	Média
29	1230855659	
93	1138610419	
23	791182792	
24	663832097	
25	297328960	
96	261286503	
38	244741137	
28	196514637	
94	190490915	
27	53933526	
Total	494457439826	

- vi.
 - vii. Ao selecionar a linha 27 da tabela “danceability”, observa-se apenas 1 faixa na tabela “acousticness”, e que também está classificada como “**baixa**” nos quartis;
- b. **5.3.2** - Validar hipótese [\(Link\)](#):
- i. Teste das hipóteses com a correlação das variáveis no **BigQuery** e criação de **Views**(sem função):
 1. Músicas com BPM (Batidas Por Minuto) mais altos fazem mais sucesso em termos de streams no Spotify;
 - a. Variáveis usadas: **bpm** / **streams_limpo**
 - b. Correlação: **-0.002437908138**
 - c. **Interpretação:** -0.0024 indica que não há uma relação linear significativa entre o BPM de uma música e o número de streams que ela tem. Ou seja, músicas com BPMs mais altos não têm mais nem menos streams apenas por causa do BPM.
 - d. **Conclusão:** O BPM não influencia significativamente no sucesso da música em termos de streams no Spotify, ao menos não de forma linear;
 2. As músicas mais populares no ranking do Spotify também possuem um comportamento semelhante em outras plataformas como Deezer;
 - a. Variáveis usadas: **in_spotify_charts** / **in_deezer_charts**
 - b. Correlação: **0.60020540383202**
 - c. **Interpretação:** Correlação de 0.60 → é uma correlação moderada a forte e positiva. Isso significa que, de forma geral, músicas populares no ranking do Spotify também tendem a ser populares no ranking do Deezer. Quando uma música aparece nos charts do Spotify, há uma boa chance de ela também aparecer nos charts do Deezer. **Conclusão:** Existe uma associação significativa entre o sucesso nas duas plataformas. Embora não seja uma correlação perfeita (não é 1.0), é forte o suficiente para indicar que há um padrão de comportamento compartilhado entre usuários das duas plataformas;

3. A presença de uma música em um maior número de playlists é relacionada a um maior número de streams;

- a. Variáveis usadas: **streams_limpo** / **in_spotify_playlists**
- b. Correlação: **0.78982215995506433**
- c. **Interpretação:** Uma correlação de ~0.79 indica que há uma associação forte e direta entre as duas variáveis: quanto mais playlists uma música aparece, maior tende a ser seu número de streams. Isso significa que a inclusão em playlists — especialmente as mais populares — tem um papel importante na visibilidade e no desempenho de uma música no Spotify. **Conclusão:** Estar presente em playlists é um dos fatores mais relevantes para o sucesso de uma música no Spotify em termos de streams. É uma das correlações mais altas que você apresentou até agora, o que indica que o algoritmo e curadoria de playlists são decisivos na performance das faixas;

4. Artistas com maior número de músicas no Spotify têm mais streams; ⚠️⚠️⚠️ REFUTADO PELO PYTHON

- a. Variáveis usadas: **qtd_musicas** / **total_streams**
- b. Correlação: **0.78097126518094984**
- c. **Interpretação:** Uma correlação de 0.78 é considerada forte e positiva. Isso significa que artistas com mais músicas disponíveis no Spotify tendem a ter mais streams no total. Faz sentido: quanto mais músicas, mais chances de aparecer em buscas, playlists, algoritmos, e mais pontos de entrada para o público. **Conclusão:** Ter um catálogo maior no Spotify está fortemente associado a um número maior de streams totais. **Mas vale lembrar:** isso não significa que todas as músicas de artistas com muitos lançamentos fazem sucesso. **Pode ser que algumas poucas músicas puxem grande parte dos streams (efeito "hits").**

5. As características da música influenciam no sucesso em termos de streams no Spotify:

- a. Variáveis usadas: (**bpm, danceability_%, valence_%, energy_%, acousticness_%, instrumentalness_%, liveness_%, speechiness_%**) / **streams_limpo**;
- b. **Correlação:**
 - i. corr_bpm: **-0.002437908138**;
 - ii. corr_danceability: **-0.10545688369141845**;
 - iii. corr_valence: **-0.04083136749**;
 - iv. corr_energy: **-0.026051488364**;
 - v. corr_acousticness: **-0.004484652700**;
 - vi. corr_instrumentalness: **-0.0449024731751097**;
 - vii. corr_liveness: **-0.04833729577983252**;
 - viii. corr_speechiness: **-0.11233299640338507**;
- c. **Interpretação Geral:** Todas as correlações são muito próximas de zero e negativas, o que indica que as características sonoras da música, isoladamente, não têm relação forte com o sucesso em número de streams. A maior correlação negativa foi com speechiness_% (-0.1123), que sugere que músicas com muitos elementos falados (como podcasts, rap muito falado ou spoken word) tendem a ter levemente menos streams, mas ainda assim a

correlação é fraca. O fato de todas serem negativas, embora fracas, pode indicar uma leve tendência de que músicas mais "comerciais" (menos faladas, menos instrumentais, menos acústicas) se saem um pouco melhor — mas essa tendência é muito tênue. **Conclusão:** As características técnicas das músicas (como BPM, dançabilidade, energia etc.) não explicam bem o sucesso em termos de streams. Fatores externos como inclusão em playlists, marketing, artista famoso, trends em redes sociais, entre outros, provavelmente têm muito mais peso na popularidade de uma música;

ii.

```
SELECT
CORR (streams_limpo, in_spotify_playlists) AS
correlation_value
FROM `projeto-2-spotify.projeto_dataset.spotify_2`

#HIPÓTESE 1:
SELECT
CORR (a.bpm, b.streams_limpo) as correlation_value2
FROM `projeto-2-spotify.projeto_dataset.technical` a
JOIN `projeto-2-spotify.projeto_dataset.spotify_2` b
ON a.track_id = b.track_id;

#HIPÓTESE 2:
SELECT
CORR (a.in_spotify_charts, b.in_deezer_charts) as
correlation_value3
FROM `projeto-2-spotify.projeto_dataset.spotify_2` a
JOIN `projeto-2-spotify.projeto_dataset.competition` b
ON a.track_id = b.track_id;

#HIPÓTESE 3:
SELECT
CORR (streams_limpo, in_spotify_playlists) AS
correlation_value
FROM `projeto-2-spotify.projeto_dataset.spotify_2`

#HIPÓTESE 4:
WITH artista_stats AS (
  SELECT
    artist_name_limpo,
    COUNT(DISTINCT track_id) AS qtd_musicas,
    SUM(streams_limpo) AS total_streams
  FROM
    `projeto-2-spotify.projeto_dataset.spotify_2`
```

```
WHERE
    artist_name_limpo IS NOT NULL AND streams_limpo IS NOT
NULL
GROUP BY
    artist_name_limpo
)
```

```
SELECT
    CORR(qtd_musicas, total_streams) AS
correlacao_musicas_streams
FROM
    artista_stats;
```

#HIPÓTESE 5

```
WITH dados_unidos AS (
    SELECT
        ti.track_id,
        sp.streams_limpo,
        ti.bpm,
        ti.`danceability_%` AS danceability,
        ti.`valence_%` AS valence,
        ti.`energy_%` AS energy,
        ti.`acousticness_%` AS acousticness,
        ti.`instrumentalness_%` AS instrumentalness,
        ti.`liveness_%` AS liveness,
        ti.`speechiness_%` AS speechiness
    FROM
        `projeto-2-spotify.projeto_dataset.technical` ti
    JOIN
        `projeto-2-spotify.projeto_dataset.spotify_2` sp
    ON
        ti.track_id = sp.track_id
    WHERE
        sp.streams_limpo IS NOT NULL
        AND ti.bpm IS NOT NULL
        AND ti.`danceability_%` IS NOT NULL
        AND ti.`valence_%` IS NOT NULL
        AND ti.`energy_%` IS NOT NULL
        AND ti.`acousticness_%` IS NOT NULL
        AND ti.`instrumentalness_%` IS NOT NULL
        AND ti.`liveness_%` IS NOT NULL
        AND ti.`speechiness_%` IS NOT NULL
)
```

```

SELECT
    CORR(streams_limpo, bpm) AS corr_bpm,
    CORR(streams_limpo, danceability) AS corr_danceability,
    CORR(streams_limpo, valence) AS corr_valence,
    CORR(streams_limpo, energy) AS corr_energy,
    CORR(streams_limpo, acousticness) AS corr_acousticness,
    CORR(streams_limpo, instrumentalness) AS
corr_instrumentalness,
    CORR(streams_limpo, liveness) AS corr_liveness,
    CORR(streams_limpo, speechiness) AS corr_speechiness
FROM
    dados_unidos;

```

iii. Teste das hipóteses com a **correlação** das variáveis no **Power BI** com **gráfico de dispersão**:

1. **Hipótese 1** - Variáveis usadas: **bpm** / **streams_limpo**;

- a. **Obs.:** Não há uma tendência clara de que à medida que o BPM aumenta, os streams aumentem ou diminuam de forma consistente. **Correlação:** Visualmente, a correlação parece ser fraca e próxima de zero. A linha pontilhada que aparece no gráfico sugere uma leve tendência negativa, mas tão sutil que pode indicar correlação fraca ou inexistente. Há músicas com BPM baixo, médio e alto que têm muitos streams, e o mesmo vale para músicas com poucos streams — ou seja, o sucesso (medido por streams) não parece depender diretamente do BPM. **Conclusão:** a correlação entre BPM e número de streams é fraca, possivelmente quase nula ou levemente negativa. Isso sugere que o BPM por si só não é um bom preditor de popularidade de uma música no Spotify.

2. **Hipótese 2** - Variáveis usadas: **in_spotify_charts** / **in_deezer_charts**;

- a. **Obs.:** os dados analisados **confirmam parcialmente** a hipótese de que as músicas mais populares no ranking do Spotify também possuem comportamento semelhante em outras plataformas, como a Deezer. O gráfico de dispersão entre a presença nos charts da Deezer (**in_deezer_charts**) e do Spotify (**in_spotify_charts**) revelou uma correlação positiva moderada ($r \approx 0,6002$), indicando que, em geral, músicas que apresentam maior popularidade no Spotify tendem a também ocupar posições de destaque na Deezer. Entretanto, a dispersão observada nos dados evidencia que esta relação não é perfeita: existem músicas que alcançam alto desempenho em uma plataforma sem necessariamente replicar o mesmo sucesso na outra. Assim, conclui-se que há uma tendência de popularidade cruzada entre Spotify e Deezer, ainda que fatores específicos de cada plataforma possam influenciar variações no desempenho de determinadas músicas;

3. **Hipótese 3** - Variáveis usadas: **streams_limpo** / **in_spotify_playlists**;

- a. **Obs.:** a análise do gráfico de dispersão entre o número de playlists (**in_spotify_playlists**) e o total de streams (**streams_limpo**) revela uma forte correlação positiva. A linha de tendência ascendente

indica que, de maneira geral, quanto maior a quantidade de playlists em que uma música aparece, maior tende a ser seu número de streams.

- b. Ainda que haja alguma dispersão — especialmente em faixas com altíssimo número de playlists ou streams —, a tendência principal é clara: a inclusão em playlists funciona como um importante mecanismo de promoção e impulsionamento do número de reproduções de uma música no Spotify. Portanto, a hipótese foi **confirmada** com base nos dados analisados;

4. **Hipótese 4** - Variáveis usadas: **qtd_musicas** / **total_streams**;

- a. Obs.: Interpretação: Concentração de pontos no canto inferior esquerdo: A maioria dos artistas tem poucas músicas e também poucos streams. Isso pode indicar que artistas menos prolíficos tendem a ter menos visibilidade ou alcance nas plataformas;
- b. Linha pontilhada horizontal (~5 músicas): Parece indicar uma média ou um limite de referência para número de músicas. Muitos pontos estão abaixo ou exatamente nessa linha, sugerindo que muitos artistas têm 5 músicas ou menos;
- c. Popularidade x Proliferação: Alguns artistas com menos músicas (abaixo da linha pontilhada) conseguem alcançar muitos streams — indicativo de que popularidade não depende necessariamente de um grande volume de músicas. Por outro lado, há artistas com muitas músicas (acima da linha pontilhada) que não têm muitos streams — o que sugere que produzir mais não garante sucesso;
- d. **Outliers**: Existem alguns pontos com streams superiores a 2 bilhões e até 3 bilhões, mas não necessariamente com um número alto de músicas. Isso reforça que a popularidade pode estar mais ligada à performance de uma ou poucas faixas de destaque, não à quantidade;
- e. **Possível Conclusão para uma Hipótese**: Se a hipótese for algo como "Artistas com mais músicas tendem a ter mais streams", o gráfico mostra que essa relação **não é forte**. Existem muitos artistas com poucos lançamentos que alcançam alto número de streams, e muitos com várias músicas que têm desempenho modesto;

5. **Hipótese 5** - Variáveis usadas:

- a. streams_limpo + bpm
- b. streams_limpo + danceability_ %
- c. streams_limpo + valence_ %
- d. streams_limpo + energy_ %
- e. streams_limpo + acousticness_ %
- f. streams_limpo + instrumentalness_ %
- g. streams_limpo + liveness_ %
- h. streams_limpo + speechiness_ %;
- i. Obs.: (inserir)

iv. Criada para ser importada no PowerBI:

1.

```
WITH artist_music_count AS (  
  SELECT  
    artist_name_limpo,  
    COUNT(DISTINCT track_id) AS qtd_musicas  
  FROM
```

```

`projeto-2-spotify.projeto_dataset.spotify_2`
WHERE
    artist_name_limpo IS NOT NULL
    AND streams_limpo IS NOT NULL
GROUP BY
    artist_name_limpo
)

SELECT
    artist_name_limpo,
    qtd_musicas
FROM
    artist_music_count
ORDER BY
    qtd_musicas DESC;

```

V. **(Oráculo 🧙) - Teste de significância** das hipóteses com **Python** no **Google Colab**:

1. **Hipótese 1:**

a. **Correlação entre BPM e Streams:**

- i. (Spearman): -0.010248769009473531
- ii. p-valor: 0.7520179059448279
- iii. **Interpretação:**
 1. **Valor da correlação (-0.0102)** - Isso indica uma correlação praticamente nula entre o número de batidas por minuto (BPM) e o número de streams no Spotify. Em outras palavras, não há relação monotônica aparente entre as duas variáveis;
 2. **p-valor (0.752)** - Um p-valor muito maior que 0.05 indica que a correlação não é estatisticamente significativa. Ou seja, essa associação fraca pode ter ocorrido por acaso;
 3. **Conclusão da Hipótese 1:** "Músicas com BPM mais altos fazem mais sucesso em termos de streams no Spotify." ❌ Rejeitada com base nesses dados. Não encontramos evidências estatísticas de que músicas com mais BPM tenham mais (ou menos) streams no Spotify;

2. **Hipótese 2:**

a. **Correlação entre Spotify e Deezer charts:**

- i. (Spearman): 0.5889212257714336
- ii. p-valor: 4.868132172329094e-90
- iii. **Interpretação:**
 1. **Correlação de 0.589 (positiva e moderada a forte)** - Isso indica que há uma relação positiva moderada entre o desempenho das músicas nos rankings do Spotify e nos rankings do Deezer. Ou seja, quando uma música tem uma boa posição

nos charts do Spotify, tende também a ter boa posição nos charts do Deezer (e vice-versa);

2. **p-valor praticamente zero** - Isso mostra que a correlação encontrada é altamente significativa estatisticamente. É muito improvável que essa correlação tenha ocorrido por acaso;
3. **Conclusão da Hipótese 2:** "As músicas mais populares no ranking do Spotify também possuem comportamento semelhante em outras plataformas como Deezer."  Confirmada com base nesses dados. As plataformas mostram consistência no desempenho das músicas;

3. Hipótese 3:

a. Correlação entre n° playlists e streams:

- i. -0.018724496096824243
- ii. p-valor: 0.5637163900482092
- iii. Interpretação:
 1. **Correlação negativa muito fraca** - O valor de -0.0187 mostra uma correlação negativa praticamente nula. Isso indica que o número de playlists em que uma música aparece não tem relação perceptível com a quantidade de streams, segundo esses dados;
 2. **p-valor alto (0.564)** - Um p-valor maior que 0.05 mostra que a correlação não é estatisticamente significativa. Ou seja, essa associação é fraca e pode ter acontecido por acaso;
 3. **Conclusão da Hipótese 3:** "A presença de uma música em um maior número de playlists é relacionada a um maior número de streams."  Hipótese rejeitada com base nesses dados. O número de playlists não mostrou influência significativa sobre o número de streams.
 4. **Curiosidade:** às vezes o tipo de playlist (e não só a quantidade) pode fazer diferença — por exemplo, estar em uma playlist editorial do Spotify costuma ter mais impacto do que estar em várias playlists pessoais. Se o seu dado separar isso no futuro, pode valer um novo teste;

4. Hipótese 4: >>> REFUTA A CORRELAÇÃO DO BIG QUERY

a. Correlação entre n° de músicas por artista e streams

- i. : -0.006847079025223792
- ii. p-valor: 0.8328098894273368
- iii. **Interpretação: Correlação fraca (quase nula):** O valor de -0.0068 indica uma correlação extremamente fraca (praticamente inexistente) entre o número de músicas que um artista tem no Spotify e a quantidade de streams das músicas. Sinal negativo: Mesmo sendo negativo, o valor é tão pequeno que não dá pra concluir nenhuma tendência real (nem que mais músicas atrapalham, nem que ajudam);
- iv. **p-valor muito alto (0.83):** Isso indica que o resultado não é estatisticamente significativo. Em outras palavras, essa correlação pode ter ocorrido por acaso e não há evidência

suficiente para afirmar que existe uma relação real entre essas variáveis;

- v. **Conclusão:** Não há evidência estatística de que artistas com mais músicas no Spotify tenham mais (ou menos) streams. A correlação observada é extremamente fraca e estatisticamente insignificante;

5. Hipótese 5:

- a. Muito extenso e complexo

10. (5.4 - Resumir informações em um dashboard ou relatório):

- a. 5.4.1 - Representar dados por meio de tabela resumo ou scorecards
- b. 5.4.2 - Representar dados através de gráficos simples
- c. 5.4.3 - Representar dados por meio de gráficos ou Recursos visuais avançados
- d. 5.4.4 - Aplicar opções de filtros para gerenciamento e interação

11. (5.5 Apresentar resultados)

- a. 5.5.1 - Selecionar gráficos e informações relevantes
- b. 5.5.2 - Criar uma apresentação
- c. 5.2.3 - Apresentar resultados com conclusões e recomendações

12. (6 - MARCO ADICIONAL) - [LINK](#)

13. (6.1 - Processar e preparar a base de dados)


- a. 6.1.1 - Conectar/importar dados para outras ferramentas

14. (6.2 Aplicar técnica de análise)

- a. 6.2.1 Regressão linear

i. HIPÓTESE 1:

1. Coeficiente de correlação: -0.0024



2.

3. **INTERPRETAÇÃO:** O coeficiente de correlação de -0.0024 indica uma praticamente inexistente correlação negativa entre BPM e streams. Vamos interpretar: O valor está muito perto de zero. Isso significa que não há uma relação linear clara entre BPM (batidas por minuto) e streams no Spotify.


- a. Sinal negativo (se tivesse sido mais forte, por exemplo, -0.8 ou algo assim) indicaria que, à medida que o BPM

aumenta, o número de streams diminui. Mas, como o valor está próximo de zero, isso não está acontecendo de forma significativa;

- b. O que isso significa na prática? Não podemos concluir que músicas com BPM mais alto realmente fazem mais sucesso no Spotify com base nesses dados. Pode ser que outros fatores estejam influenciando mais o número de streams, ou talvez o BPM não seja uma variável tão importante;
- c. O que fazer agora? Explorar mais variáveis: Talvez o danceability, energy, ou valence (ou outras características musicais) estejam mais relacionados aos streams. Tentar outros tipos de análise: Por exemplo, usar regressão múltipla para ver como diferentes fatores influenciam os streams ao mesmo tempo.

ii. HIPÓTESE 2:

1. Coeficiente de correlação: 0.6002




2.

3. INTERPRETAÇÃO:

- a. O coeficiente de correlação de 0.6002 significa que existe uma correlação positiva moderada entre o ranking no Spotify e o ranking no Deezer.
- b. Como interpretar 0.6002 é um valor positivo e não muito próximo de 1, o que indica que há uma relação positiva entre as duas variáveis. Isso significa que, de forma geral, quando uma música é popular no Spotify, ela tende a ser popular também no Deezer, mas não é uma relação perfeita.
- c. A força da correlação é moderada, o que significa que não é 100% certo que as músicas populares no Spotify estarão necessariamente populares no Deezer. Ou seja, há outros fatores que podem afetar essa relação, mas ainda assim, a tendência é visível.

iii. HIPÓTESE 3:

1. Coeficiente de correlação: 0.7898




2.

3. INTERPRETAÇÃO:

- Interpretação:** valor positivo (0.7898): Há uma relação positiva entre as duas variáveis. Isso significa que, em geral, conforme o número de playlists em que a música aparece aumenta, também tende a aumentar o número de streams dessa música;
- Força da correlação:** O valor 0.7898 está próximo de 1, o que indica uma correlação forte, mas não perfeita. Isso sugere que, embora haja uma relação significativa, ainda pode haver outros fatores que influenciam o número de streams, além da presença em playlists;
- Conclusão:** a hipótese que "A presença de uma música em um maior número de playlists é relacionada a um maior número de streams" parece ser bem sustentada pelos dados, já que o coeficiente de correlação é bastante alto. Isso indica que, de fato, a inclusão de uma música em playlists populares tende a ter um impacto significativo no número de vezes que ela é ouvida no Spotify;

iv. HIPÓTESE 4: Coeficiente de correlação: 0.7809 !



1.

2. INTERPRETAÇÃO:

- A regressão linear tenta ajustar uma linha reta (ou função linear) que melhor se encaixa nos dados. Isso gera a reta de tendência, que é o que você viu com a

linha vermelha nos gráficos. A regressão linear pode ter um coeficiente de 0.7809, indicando que, com a quantidade de músicas, há uma forte tendência de aumento no número de streams;

- b. (MAS...) Já a correlação de Pearson de -0.0068 indica que não há uma relação forte ou significativa entre as duas variáveis (pelo menos do ponto de vista da correlação simples).

v. **HIPÓTESE 5:**

1. **GRÁFICOS;**

2. **INTERPRETAÇÃO:**

- a. A análise de regressão linear múltipla indicou que as características técnicas das músicas explicam apenas 2,9% da variação no número de streams no Spotify, sugerindo uma influência limitada. Algumas variáveis, como danceabilidade e speechiness, mostraram impacto estatisticamente significativo, porém com efeito negativo, o que pode indicar uma preferência do público por músicas menos faladas e menos dançantes em certos contextos. No entanto, a baixa capacidade explicativa do modelo aponta que fatores externos às características sonoras — como a popularidade do artista, estratégias de divulgação e presença em playlists — provavelmente exercem um papel mais determinante no sucesso das faixas.
- b. **CONCLUSÃO GERAL:** A análise mostra que a popularidade de uma música é mais influenciada por sua presença em playlists e por estratégias de publicação (como volume de lançamentos) do que por características técnicas isoladas;

b. 6.2.1 Regressão Linear (Parte 2) - **Gráficos** com **PACOTE MATPLOTLIB:**

- i. **HIPÓTESE 1 - OK**
- ii. **HIPÓTESE 2 - OK**
- iii. **HIPÓTESE 3 - OK**
- iv. **HIPÓTESE 4 - OK**
- v. **HIPÓTESE 5 - OK**

QUADRO RESUMO

	BigQuery	Power BI	Python - Teste de significância	Regressão Linear (Marco Adicional)
HIPÓTESE 1: Músicas com BPM	Correlação: -0.002437908138	Gráfico	(Spearman): -0.0102487690094	Coefficiente de correlação: -0.0024

(Batidas Por Minuto) mais altos fazem mais sucesso em termos de streams no Spotify;			73531 p-valor: 0.7520179059448279	
	Não confirmou	Não confirmou	Não confirmou	Não confirmou
HIPÓTESE 2: As músicas mais populares no ranking do Spotify também possuem um comportamento semelhante em outras plataformas como Deezer	Correlação: 0.60020540383202	Gráfico	(Spearman): 0.5889212257714336 p-valor: 4.868132172329094e-90	Coefficiente de correlação: 0.6002
	Confirmou	Confirmou	Confirmou	Confirma
HIPÓTESE 3: A presença de uma música em um maior número de playlists é relacionada a um maior número de streams;	Correlação: 0.78982215995506433	Gráfico	-0.018724496096824243 p-valor: 0.5637163900482092	Coefficiente de correlação: 0.7898
	Confirmou	Confirmou	Não confirmou	Confirma
HIPÓTESE 4: Artistas com maior número de músicas no Spotify têm mais streams;	Correlação: 0.78097126518094984	Gráfico	-0.006847079025223792 p-valor: 0.8328098894273368	Coefficiente de correlação: 0.7809 Correlação de Pearson de -0.0068
	Confirmou, mas: ⚠️⚠️⚠️ REFUTAD O PELO PYTHON - Signif.	Não confirmou	Não confirmou	Não confirmou
HIPÓTESE 5: As características da música influenciam no sucesso em termos de streams no Spotify;	Todas as correlações negativas	x	x	Regressão múltipla
	Não confirmou	x	x	Não confirmou

	BigQuery	Power BI	Python - Teste de significância	Regressão Linear (Marco Adicional)
HIPÓTESE 1: Músicas com BPM (Batidas Por Minuto) mais altos fazem mais sucesso em termos de streams no Spotify;	Não confirmou	Não confirmou	Não confirmou	Não confirmou
HIPÓTESE 2: As músicas mais populares no ranking do Spotify também	Confirmou	Confirmou	Confirmou	Confirma

possuem um comportamento semelhante em outras plataformas como Deezer				
HIPÓTESE 3: A presença de uma música em um maior número de playlists é relacionada a um maior número de streams;	Confirmou	Confirmou	Não confirmou	Confirma
HIPÓTESE 4: Artistas com maior número de músicas no Spotify têm mais streams;	Confirmou, mas: 🚨🚨🚨 RE FUTADO PELO PYTHON - Signif.	Não confirmou	Não confirmou	Não confirmou
HIPÓTESE 5: As características da música influenciam no sucesso em termos de streams no Spotify:	Não confirmou			Não confirmou